Extractor de facturas FEL con LLM

CC3092 Deep Learning – Proyecto 3: Casos de uso de LLM

Feria científica, 2 de noviembre de 2026

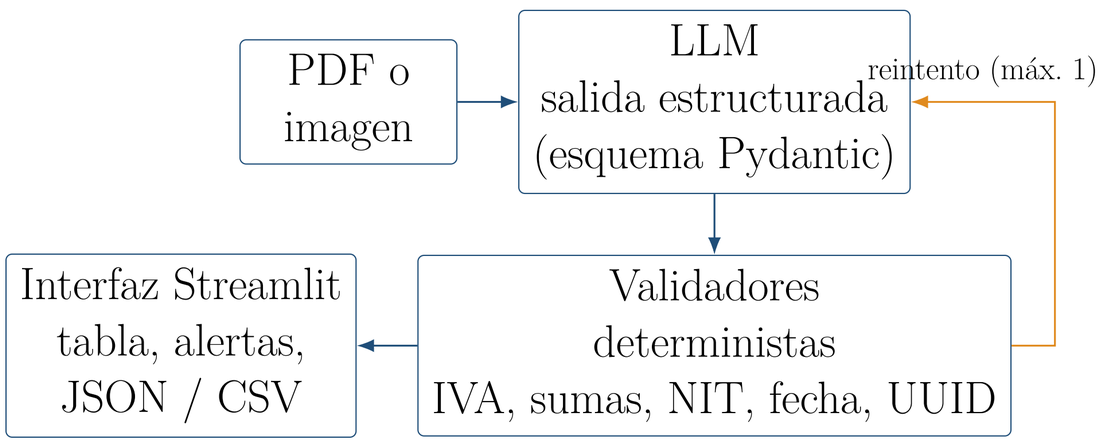
Problema

Pymes y contadores en Guatemala reciben facturas FEL en PDF o imagen, con layouts distintos, y las digitan a mano en hojas de cálculo. Es lento y propenso a errores.

Objetivo: subir una factura y obtener un JSON/CSV revisable, con los campos dudosos marcados para revisión humana.

¿Por qué un LLM? Las reglas (regex) no escalan a layouts, ruido y fotos: el baseline solo acierta el 23 % de los campos.

Pipeline



Modelos comparados: `gpt-4o-mini` (OpenAI), `claude-haiku-5-5` y `claude-sonnet-5-5` (Anthropic). Técnica: prompting + esquema + validación; sin RAG ni fine-tuning.

Datos de evaluación

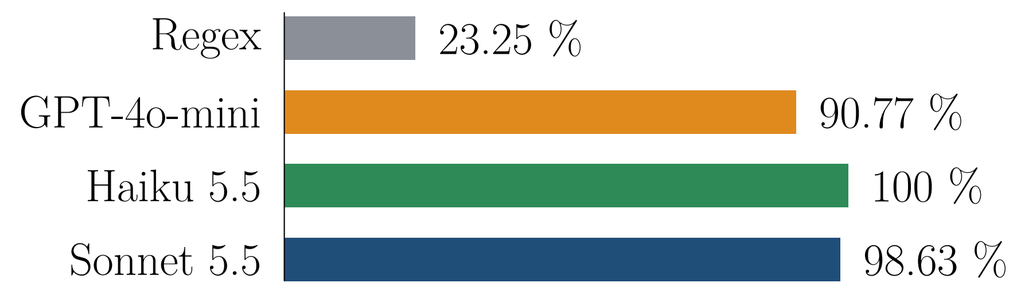
- **45 facturas FEL sintéticas** (semilla 2026): 4 layouts, PDF e imagen, 3 formatos de fecha, 1–8 líneas, ruido, rotación y desenfoque.
- **15 fixtures públicas** (Shopify Invoice Test Pack, CC BY 4.0): multipágina, árabe, descuentos, flete, mala calidad.

Prompt v1 mínimo → v2 con reglas de nulos, normalización y defensa contra instrucciones incrustadas en el documento.

Pruébalo

Código, README y reproducción de métricas:
github.com/Javier-Espana/PRY3-DL

Resultados principales: 45 facturas FEL



Exactitud por campo, sin reintentos

Sistema	Docs. 100 %	Latencia	USD/doc.
Regex	0 %	–	0
GPT-4o-mini	15,56 %	4,9 s	0,00147
Haiku 5.5	**100 %**	5,3 s	**0,00076**
Sonnet 5.5	82,22 %	4,0 s	0,0113

En el conjunto FEL, Haiku 5.5 fue la mejor relación precisión/costo: 100 % de exactitud a USD 0,00076 por documento. Sonnet costó unas 15 veces más y obtuvo 98,63 %. Costo total de las tres corridas: ≈ USD 0,61 (prompt v2, 0 reintentos, 2.000 tokens de salida).

Robustez y hallazgos

- **Prueba secundaria (15 fixtures públicas internacionales):** GPT-4o-mini 72,31 %, Haiku 83,08 % y Sonnet 91,28 % (USD 0,01162 vs. 0,00078 por documento). Sonnet fue mejor allí, a 15 veces el costo. Son documentos árabes, bilingües, con descuentos y flete; no miden desempeño FEL.
- **La elección del modelo depende del dominio y del presupuesto:** la recomendación de Haiku es específica del conjunto FEL evaluado.
- **Error de etiquetado hallado y corregido:** 6 facturas sin IVA tenían `subtotal` en el gold sin que el documento lo mostrara.
- **Compromiso del prompt v2:** "null si no aparece" evita inventar, pero deja vacía la moneda cuando solo dice "Q".

Limitaciones

- El conjunto principal es sintético y lo creó el mismo equipo que el extractor: techo de rendimiento probable.
- Falta validar con facturas reales anonimizadas y con usuarios externos.
- Las facturas se envían al proveedor del modelo: no subir